

Федеральное государственное автономное образовательное учреждение
высшего образования «Санкт-Петербургский политехнический университет
Петра Великого»

Отчет по практическому занятию
«Наука о данных и аналитика больших объемов информации»

Практическая работа 4
«Создание индекса и запись данных в Elasticsearch»

Выполнил работу
ст. гр. 3740105/50101
Белаш Андрей Анатольевич
Проверил преподаватель
Соломонов Максим Сергеевич

Санкт-Петербург,
2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
ХОД РАБОТЫ.....	4
1. Загрузка демонстрационных наборов данных	4
2 Создание аналитических визуализаций.....	8
ЗАКЛЮЧЕНИЕ	14

ВВЕДЕНИЕ

Kibana предоставляет широкий спектр продвинутых инструментов для визуализации и анализа данных, выходящих за рамки базовых диаграмм и таблиц.

В рамках данного практического задания изучаются расширенные возможности Kibana:

- Discover — исследование структуры данных и документов;
- Dashboard — сложные интерактивные рабочие столы с фильтрами;
- Canvas — креативные презентации данных с наложением графики;
- Graph — анализ связей между объектами;
- Machine Learning — поиск аномалий и выбросов в данных.

Для изучения этих возможностей загружаются демонстрационные наборы данных, а также создаются продвинутое визуализации для проекта «Аналитика IT-вакансий».

Основная цель: получить представление о продвинутых возможностях анализа и визуализации данных в Kibana.

Задачи работы:

- 1) загрузить 3 демонстрационных набора данных в Kibana;
- 2) изучить модели данных (объекты, атрибуты, связи);
- 3) исследовать примеры Dashboard, Canvas, Graph для демонстрационных данных;
- 4) создать сложный аналитический Dashboard для проекта «IT-вакансии»;
- 5) построить Canvas-презентацию с визуализацией данных;
- 6) создать графовое представление связей между объектами;
- 7) изучить возможности обнаружения выбросов в данных.

ХОД РАБОТЫ

1. Загрузка демонстрационных наборов данных

Шаг 1. Открытие Kibana и переход на главную страницу (рис. 1).




Рисунок 1 - Главная страница Kibana

Загрузка 3 наборов данных: (рисунки 2-4)

- Sample eCommerce orders;
- Sample flight data;
- Sample web logs.




Рисунок 2 – Sample eCommerce orders




Рисунок 3 – Sample flight data



Рисунок 4 – Sample web logs

A. Sample eCommerce Data (рисунок 2)

Dashboard демонстрирует аналитику интернет-магазина.

- Метрики: Общее количество транзакций в день (148 Trxns/day), общая выручка (\$76,934.13), средняя цена заказа (\$74.55).

Визуализации:

- Круговая диаграмма «Sales by Gender» (распределение покупок по полу: Male 48.93%, Female 51.07%).

- Графики среднего количества проданных товаров.

- Стековая диаграмма "Sales by Category" (продажи по категориям товаров во времени).

- Фильтры: Возможность фильтрации по производителю, категории и количеству.

B. Sample Flight Data

Dashboard показывает статистику авиаперевозок.

- Метрики: Общее количество рейсов (319), средняя цена билета (\$600.91), количество задержек (66) и отмен (38).

Визуализации:

- Круговая диаграмма «Airline Carrier» (доли авиакомпаний: Logstash Airways, ES-Air, JetBeats, Kibana Airlines).

- Точечная диаграмма «Flight Count and Average Ticket Price» (зависимость цены от времени).

- Графики задержек и отмен рейсов.

- Фильтры: Город вылета/прилета, цена билета.

C. Sample Web Logs Data

Dashboard для анализа логов веб-сервера.

- Метрики: Уникальные посетители (802 Unique Visitors).

Визуализации:

- Круговая диаграмма «Visitors by OS» (распределение по ОС: win 8, osx, ios, win xp, win 7).

- График «Response Codes Over Time» (коды ответов сервера 200, 404, 503 во времени).

- Пузырьковая диаграмма «Unique Visitors vs. Average Bytes».

- Таблица "Host, Visits and Bytes Table" с детализацией по типам файлов (css, gz, zip).

Исследование Canvas-презентации. Canvas позволяет создавать креативные презентации с комбинацией текста, графиков, иконок и изображений. Данные обновляются в реальном времени.

Graph показывает связи между объектами:

- eCommerce: пол покупателя ↔ категория товара ↔ континент

- Flights: город вылета ↔ город прилета ↔ авиакомпания

Толщина линии показывает силу связи (количество документов).

Machine Learning автоматически обнаруживает аномалии в данных: (рисунок 5)

- необычно высокие/низкие значения;
- отклонения от нормальных паттернов;
- подозрительная активность.



Рисунок 5 – Machine Learning Dashboard

Аномально высокие зарплаты:

- некоторые вакансии с зарплатой больше 500,000 руб;
- это редкие позиции уровня C-level или ведущих инженеров.

Аномально низкие зарплаты:

- вакансии с зарплатой меньше 10,000 руб;
- возможны ошибки в данных или стажировки.

Необычные комбинации:

- Junior-позиции с зарплатой уровня Senior;
- Senior-позиции с очень низкой зарплатой.

Временные аномалии:

- резкие скачки количества вакансий в определенные периоды;
- необычное снижение активности в рабочие дни.

2 Создание аналитических визуализаций

Далее создадим 3 дашборда:

1) Горизонтальная гистограмма распределения зарплат:




Рисунок 6 – Горизонтальная гистограмма распределения вакансий по опыту работы

Далее была построена тепловая карта городов и востребованных языков программирования (рисунок 7).




Рисунок 7 – Heatmap городов и языков программирования

Москва лидирует по количеству вакансий (особенно Java, 1C), Санкт-Петербург на втором месте. Остальные города имеют значительно меньше вакансий. Наиболее востребованные языки: Java, 1C, SQL, PHP.

Далее построим линейный график трендов зарплат по времени (рисунок 8).




Рисунок 8 – Линейный график трендов зарплат

График показывает относительно стабильный тренд средней заработной платы на протяжении рассматриваемого периода.

Наблюдается незначительное снижение значений в начале временного ряда, после чего уровень стабилизируется.

Высокие значения на оси Y (15-20 млн) могут указывать на наличие выбросов (вакансий с экстремально высокой зарплатой) в датасете, которые влияют на среднее арифметическое.

Далее был построен общий дашборд с фильтрами по городам (рис. 9).




Рисунок 9 – Дашборд вакансий

Пример для города Казани с заработной платой 60000 руб. представлен на рисунке 10.




Рисунок 10 – Распределение вакансий по городу Казань

Canvas используется для создания красивых презентаций данных в реальном времени. На холсте "Аналитика IT-вакансий 2020" представлены следующие элементы:

Метрика «Salary Average» (94,199.36) – показывает среднюю заработную плату по всем вакансиям в выбранной выборке. Это агрегированное значение (Average) поля salary.from.

Круговая диаграмма «Распределение вакансий по опыту работы» – визуализирует долю вакансий для разных уровней специалистов. Синий сегмент (самый большой) показывает, что большинство вакансий требуют опыта «От 1 года до 3 лет» (Middle).

Столбчатая диаграмма «Распределение вакансий по город» - показывает количество вакансий в разных городах. Столбец «Москва» самый высокий, что означает наибольшую концентрацию рабочих мест в столице.

Фильтры (Город, Зарплата) – демонстрируют интерактивность Canvas. На скриншоте применен фильтр по городу «Казань» и зарплате «60,000». Это позволяет мгновенно пересчитать метрики только для выбранных условий.

Далее был построен граф (рисунок 11).




Рисунок 11 – Граф вакансий

Граф позволяет визуализировать и исследовать скрытые связи между объектами в данных на основе их совместной встречаемости в документах.

ЗАКЛЮЧЕНИЕ

В ходе выполнения практического задания №5 были изучены и применены продвинутое возможности аналитической платформы Kibana для исследования данных о IT-вакансиях.

Основные результаты работы:

1) Изучены демонстрационные наборы данных:

- проанализированы три готовых набора: eCommerce orders, flight data, web logs;
- исследованы структуры данных, типы полей и взаимосвязи;
- оценены возможности готовых Dashboard для бизнес-аналитики.

2) Создан комплексный Dashboard для IT-вакансий:

Разработаны новые визуализации: горизонтальная гистограмма распределения зарплат, тепловая карта городов и языков, линейный график трендов:

- настроены интерактивные фильтры (город, опыт, зарплата);
- реализована динамическая связь между визуализациями.

Построен Canvas (Холст):

- создана презентация данных с метриками (средняя зарплата, количество вакансий);
- добавлены круговые диаграммы и таблицы;
- настроены интерактивные фильтры для мгновенного пересчета показателей.

Создан Граф связей:

- визуализированы связи между городами, технологиями, работодателями и уровнями опыта;
- выявлены скрытые зависимости и кластеры.

Изучены возможности Machine Learning:

- рассмотрены принципы автоматического обнаружения аномалий;
- выявлены выбросы в данных (аномально высокие/низкие зарплаты).